

TP : Création d'un Chatbot basé sur un RAG

Le TP vise à concevoir un système RAG (Retrieval-Augmented Generation) capable de répondre à des questions d'utilisateurs en s'appuyant sur des données de Wikipédia sur la thématique de l'IA générative. Vous allez mettre en œuvre l'ensemble des étapes d'un pipeline RAG :

- Récupération et préparation de documents,
- Indexation et recherche sémantique,
- Génération de réponses contextuelles avec un modèle pré-entraîné.

Étapes du TP

1. Préparation des données

Vous allez récupérer un ensemble de pages Wikipédia portant sur l'IA générative. Ces pages constitueront la base documentaire de votre chatbot.

- Télécharger les contenus des pages Wikipédia sélectionnées (par exemple : *IA générative*, *GPT*, *Google Gemini*, *Transformers*, etc.).
- Stocker les textes dans un format exploitable (JSON, CSV,...).
- Nettoyer les textes : suppression des balises, normalisation des caractères, etc.

2. Indexation des documents et récupération

Indexer les documents pour permettre leur recherche rapide et pertinente.

- Découper les documents en *chunks* de taille adaptée (par exemple 500–1000 tokens).
- Créer des **embeddings** pour chaque chunk à l'aide de `OpenAIEmbeddings`.
- Stocker ces embeddings dans une base vectorielle (`Chroma`).
- Implémenter une fonction `retrieve_documents(query)` qui :
 - génère plusieurs reformulations de la requête utilisateur ;
 - récupère les documents les plus pertinents pour chaque reformulation ;
 - fusionne et trie les résultats.
 - renvoie les 5 documents les plus pertinents.

3. Génération de la réponse

Vous allez maintenant utiliser un modèle de génération (GPT-4-o) pour produire la réponse finale.

- Utilisez les documents renvoyés par `retrieve_documents` comme contexte.
- Générez la réponse en **mode streaming** (flux continu).
- Affichez, à la fin de chaque réponse, les liens vers les pages Wikipédia d'où proviennent les informations.